

Análisis de Transiciones: Pipeline de Experimentación

Máster en Inteligencia Artificial - Asignatura MLOps

Grupo B

19 de febrero de 2026

Transiciones asignadas: Data Analysis → Validation → Training → Model
Validation → Handover

1. Flujo de Datos: De la Ingesta al Entrenamiento

En este bloque, los datos pasan de ser analizados a estar listos para enseñar al modelo:

- **Data Analysis → Data Validation:**

- **Tipo:** Movimiento de Datos/Artefactos.
- **Qué sucede:** Se transfieren las reglas y esquemas descubiertos durante el análisis para asegurar que los datos futuros sean correctos.
- **Herramienta:** **Great Expectations** (define contratos de calidad de datos).

- **Data Validation → Model Training:**

- **Tipo:** Movimiento de Datos/Artefactos (Dashed arrow).
- **Qué sucede:** Solo los datos que superan el control de calidad entran al proceso de entrenamiento.
- **Herramienta:** **DVC** (Data Version Control) para rastrear qué versión exacta de datos se usó.

2. Flujo del Modelo: Del Entrenamiento a la Entrega

Una vez entrenado el modelo, debe ser validado antes de ser aceptado oficialmente:

- **Model Training → Model Validation:**
 - **Tipo:** Movimiento de Artefactos.
 - **Qué sucede:** El archivo del modelo entrenado se envía para ser probado con datos nuevos (test).
 - **Herramienta:** **MLflow** (registra el modelo y sus resultados).
- **Model Validation → Model Handover:**
 - **Tipo:** Movimiento de Metadatos (Dotted arrow).
 - **Qué sucede:** Se entregan las métricas (precisión, error) y la documentación técnica para decidir si el modelo se guarda.
 - **Herramienta:** **MLflow Model Registry**.

3. Tabla Resumen de Transiciones

Transición	Tipo	Dato/Formato	Herramienta	Mitigación (Fallo)
Analysis → Val.	Datos	Esquema (JSON)	Great Expectations	Rollback de esquema
Val. → Training	Datos	Dataset Validado	DVC	Parada automática
Training → Val.	Artif.	Modelo (.pkl/.onnx)	MLflow	Checkpoints intermedios
Val. → Handover	Metad.	Métricas (CSV/JSON)	Model Registry	Aprobación humana

4. Caso Real: Inspección de Pantallas en Fábrica

Contexto: Automatizar la detección de grietas usando fotos de cámaras en la línea de montaje.

- **Data Analysis:** Analizamos las fotos para entender cómo se ven las grietas y si el brillo de la fábrica afecta la imagen.
- **Data Validation:** El sistema descarta automáticamente fotos borrosas o con poca luz antes de intentar procesarlas.
- **Model Training:** La IA aprende a distinguir entre una grieta real (defecto) y un simple reflejo de la luz.
- **Model Validation:** Usamos el **Shadow Mode** para ver si la IA detecta los mismos fallos que el inspector humano, sin detener la fábrica aún.
- **Model Handover:** Una vez que la IA es fiable, entregamos el modelo al software que controla la cinta transportadora para separar las pantallas malas.

5. Reflexión Transversal

- **Metadatos vs Datos:** El flujo de datos es la materia prima (el dataset), mientras que los metadatos son la etiqueta con información sobre su calidad y origen.
- **Fallo a las 3:00 AM:** El sistema de monitoreo detecta el error y activa una alerta al equipo. El *Orchestrator* detiene las etapas siguientes para evitar que un modelo defectuoso avance.
- **Punto Crítico:** El **Model Training** es el cuello de botella por su alto consumo de recursos. Se resuelve con gestión eficiente de recursos (GPUs/Nube).